Машинное обучение

Основано на лекциях Уразовой И.В.

Конспект написан Заблоцким Данилом

Весенний семестр 2025

Эти записи не одобряются лекторами, и я вношу в них изменения (часто существенно) после лекций. Они далеко не точно отражают то, что на самом деле читалось, и, в частности, все ошибки почти наверняка мои.

Оглавление

0.0.1 Обучение с учителем 3
0.0.2 Обучение без учителя 3
0.0.3 Кластерный анализ 4
0.0.4 Предобработка данных 4
0.0.5 Нормализация данных 4
0.0.6 Ошибки. Оценки и проверка гипотез 5
0.0.7 Ошибки. Оценки и проверка гипотез 5
0.0.8 Промежуточные выводы 6
0.1 Глубокое обучение 6
0.2 Обучение нейронной сети 7
0.3 Компьютерное зрение 8
0.4 Нейросети и их типы 8

Лекция 2: Продолжение

от 11 мар 12:45

0.0.1 Обучение с учителем

Определение 1 (Supervised learning). *Sypervised learning* – наиболее распространенный случай. Каждый прецедент представляет собой пару "объект, ответ". Требуется найти функциональную зависимость ответов от описаний объектов и построить алгоритм, принимающий на входе описание объекта и выдающий на выходе ответ.

Функционал качества обычно определяется как средняя ошибка ответов, выданных алгоритмом по всем объектам выборки.

Определение 2 (Задача классификации, класс). *Задача классификации* отличается тем, что множество допустимых ответов конечно. Их называют метками классов. *Класс* – это множество объектов с данным значением метки.

Определение 3 (Задача регрессии). *Задача регрессии* отличается тем, что допустимым ответом ялвяется действительное число или числовой вектор.

Определение 4 (Задача ранжирования). *Задача ранжирования* отличается тем, что ответы надо получить сразу на множестве объектов, после чего отсортировать их по значениям ответов. Может сводиться к задачам классификации или регрессии. Часто применяется в информационном поиске и анализе текстов.

Определение 5 (Задача прогнозирования). *Задача прогнозирования* отличается тем, что обхектами являеются отрезки временных рядов, обрывающиеся в тот момент, когда требуется сделать прогноз на будущее. Для решения задач пронозирования часто удается приспособить методы регрессии...

0.0.2 Обучение без учителя

Определение 6 (Обучение без учителя). *Обучение без учителя.* В этом случае ответы не задаются, и требуется искать зависимости между объектами.

Определение 7 (Задача кластеризации)**.** *Задача кластеризации* заключается в том, чтобы сгруппировать объекты в кластеры, используя данные о попарном сходстве объектов. Функционалы качетсва могут определяться по-разному, например, как отношение средних межкластерных и внутрикластерных расстояний.

0.0.3 Кластерный анализ

Определение 8 (DBSCAN)**.** *DBSCAN* – это алгоритм кластеризации, основанный на плотности.

Лекция 3: Продолжение

от 25 мар 12:45

Типы МЛ

При обучении с учтелем – функционал качества может определяться как средняя ошибка ответов. Предполагается, что искомый алгоритм должен его минимизировать.

Определение 9 (Задача классификации)**.** задача присвоения меток объектам.

Определение 10 (Задача регрессии)**.** *Задача регресии* – это задача предсказания одной непрерывной случайной величины $\nu : \Omega \to Y$ на основе значений других случайных величин $\Xi_i : \Omega \to X_i$.

0.0.4 Предобработка данных

Составляет более 80% времени, затрачиваемого на большинство проектов по искусственному интелекту и машинному обучению.

Проекты AI, относящиеся к распознаванию объектов / изображений, автономного транспорту и аннотированию текста и изображений, являются наиболее распространенными задачами при разметке данных.

0.0.5 Нормализация данных

Определение 11 (Нормализация)**.** *Нормализация* – это способ организации данных. В нормализованной базе нет повторяющихся данных, с ней проще работать и можно менять её структуру для разных задач. В процессе нормализации данные преобразуют, чтобы они занимали меньше места, а поиск по элементам был быстрым и результативным.

Определение 12 (Третья нормальная форма (3NF)). 2NF + каждый неключевой атрибут нетразитивно функционально зависит от первичного ключа (каждое неключевое поле должно содержать информацию о ключе, полном ключе и ни о чем, кроме ключа).

Определение 13 (Очистка данных). *Очистка данных* – это процесс исправления или удаления неправильных, поврежденных, дублированных данных в пределах набора данных. Этапы процесса очистки данных зависят от конкретного набора данных.

0.0.6 Ошибки. Оценки и проверка гипотез

Определение 14 (Ошибка первого рода). *Ошибка первого рода* – ситуация, когда отвергнута верная нулевая гипотеза.

Определение 15 (Ошибка второго рода). *Ошибка второго рода* – ситуация, когда принята неверная нулевая гипотеза.

Лекция 4: Продолжение

от 8 апр 12:45

0.0.7 Ошибки. Оценки и проверка гипотез

Определение 16 (Ошибка первого рода). *Ошибка первого рода* – ситуация, когда отвергнута верная нулевая гипотеза.

Определение 17 (Ошибка второго рода). *Ошибка второго рода* – ситуация, когда принята неверная нулевая гипотеза.

Лекция 6: Продолжение

от 6 мая 12:45

Градиент, который мы только что нашли, показывает *направление скорейшего подъема* (возрастания) функции.

Нам же, если мы хотим найти минимум функции, нужно двигаться вниз...

Определение 18 (Метод градиентного спуска). *Метод градиентного спуска* – это способ нахождения локального минимума функции в процессе движения в направлении антиградиента.

Примечание. При этом, если мы сдвинемся на всю величину градиента, то "перескочим"...

- после ста итераций в примере, как веса модели, так и уровень ошибки приблизились к нулю;
- более сложные функции потерь потребуют большего количества итераций и более тонкой настройки коэфициента скорости обучения.

0.0.8 Промежуточные выводы

1. Градиент показывает скорость изменения многомерной функции по каждому из измерений.
2. Если "заморозить"все независимые переменные кроме одной и сделать срез, то наклон казательной к кривой среза будет значением частной производной по этому измерению.
3. Градиент показывает направление скорейшего подъема функции. Двигаясь в обратном направлении, мы придем к минимуму функции.

0.1 Глубокое обучение

1. Определения.
2. DL vs ML
3. Классы DL.
4. Струткра модели DL.
5. Нейросети.

Определение 19 (Искусственный интелект)**.** *Искусственный интелект* – это способность компьютеров решать задачи при помощи вычислений.

Проводить кластерный анализ. Обученные без учителя нейронные сети лучше всего справляются с задачей кластеризации – делением большого массива данных на группы. Нейросеть способна выделить критерии отличия и иоделить данные на их основе. А потом с группами уже смогут работать люди, находя нужные тенденции и проводя аналитику.

Выявлять аномалии. Для этого нейросить сначала обучают на нормальных данных, и, когда в реальности она встречается с выбросами, то должна об этом сигнализировать. Так можно быстро обнаруживать необычное поведение покупателей, например резкий рост спроса на конкретный товар.

Находить ассоциации. Нейросеть может определить критерии похожести одних объектов на другие и строить связи.

Например, рекомендовать товары в дополнение к купленным.

Лекция 7: Продолжение

от 3 июня 12:45

Определение 20 (Нейронная сеть)**.** *Нейронная сеть* – математическая модель, а также ее программное или аппаратное воплощение, построенная по принципу организации биологических нейронных сетей – сетей нервных клеток живого организма.

Примечание. После разработки алгоритмов обучения получаемые модели стали использовать в практических целях: в задачах прогнозированния, для распознавания образов, в задачах управления и т.д.

1. С точки зрения машинного обучения, нейронная сеть представляет собой частный случай методов распознования образов.

2. С точки зрения математики, обучение нейронных сетей – это многопараметрическая задача нелинейной оптимизации.

Пример. *Простой пример* нейронной сети, которая на входе получает рост и вес человека, а на выходе предсказывает пол. Скрытый слой в данном случае мы использовать не будем. В качестве функции активации возьмем сигмоиду. Ее часто используют в задачах бинарной (состоящей из двух классов) классификации. ◇

0.2 Обучение нейронной сети

Как и с традиционными алгоритмами ML, для построения модели, необходимо подобрать оптимальные веса или заняться оптимизацией. Применительно к нейронным сетям этот процесс называется *обратным распространением.*

Примечание. Мы как бы двигаемся в обратную сторону и, уже зная результат (и уровень ошибки), с учетом имеющихся данных, рассчитываем, как нам нужно изменить веса и смещения, чтобы уровень ошибки снизился.

Если *сигмоида* подходит для бинарной классификации, то *softmax* применяется для задач многоклассовой классификации.

На выходе получается вероятностное распределение любого количества классов (K).

Примечание. Настроек три:

- тип функции определяет, как мы будем считать отклонение прогнозного значения от истинного;
- способ или алгоритм оптимизации этой функции поможет снизить потерю или ошибку и подобрать правиьные веса в процессе back propagation;
- метрика покажет, насколько точна созданная модель.

0.3 Компьютерное зрение

Определение 21 (Компьютерное зрение)**.** *Компьютерное зрение* – это область, которая занимаеся анализом фото или видео изображений. Построенные на основе этого анализа модели помогают смартфонам узнавать своих владельцев, дорожным камерам распознавать номера автомобилей, а роботам объезжать препятствия.

Примечание. Любое цифровое изображение – это по сути матрица, а в случае Питона, массив Numpy, в котором *пикселей* (составных частей) задано...

В случае черно-белого изображения, или правильнее сказать, изображения в оттенках серого, речь идет об одном слое матрицы.

0.4 Нейросети и их типы

- Перцептрон: Основа Искусственного Интелекта;
- Многослойные Перцептроны (MLP): Строим Будущее С Искусственным Интелектом;
- Рекуррентные Нейронные Сети (RNN): Магия Последовательностей (временные ряды, тексты);
- Сверточные Нейронные Сети (CNN): Глаза Искусственного Интелекта (компьютерное зрение).